

# Исследование нестационарных и неоднородных динамических систем

Ivan Ilyin, Kirill Semkin, Alexander Terentyev, Vadim Strijov

24 апреля 2025 г.

## 1 Abstract

В работе исследуется задача восстановления скрытой динамической системы по временному ряду. Предполагается, что динамическая система параметризована. Для нахождения параметра системы используется метод Neural ODE. Строятся фазовые траектории в зависимости от начальных условий и параметра, восстанавливается параметр в случае зависимости его от времени. Проводится анализ точек разладки временного ряда по полученному параметру системы. Эксперимент проведён на синтетических данных и датасетах Run or Walk, The Weather Dataset.

**Keywords** : Machine Learning, Time Series, Neural ODE.

## 2 Introduction

Одним из способов исследования временных рядов является анализ скрытых состояний динамической системы, порождающей этот ряд. Временной ряд — последовательно измеренные через некоторые (зачастую равные) промежутки времени данные. Динамическая система — это математическая модель, заданная дифференциальным уравнением

$$\frac{d}{dt}\mathbf{X}(t) = f(\mathbf{X}(t), t, \mathbf{w}) \quad (1)$$

Если правая часть уравнения явно зависит от  $t$ , то динамическую систему называют нестационарной. А если правая часть уравнения пред-

ставляется в виде

$$f(\mathbf{X}, t, \mathbf{w}) = A(t)\mathbf{X}(t) + B(t, \mathbf{w}), \quad B(t, \mathbf{w}) \neq 0 \quad (2)$$

то динамическую систему называют неоднородной.

На текущий момент существует несколько подходов к восстановлению состояния системы.

Одним из методов является использование RNN [1], однако основным недостатком подхода является дискретное представление изменения состояния скрытой системы, а также неустойчивость к нерегулярно наблюдаемым данным [2]. Также скрытые состояния RNN трудно интерпретируемы [3] [4].

В [5] вводятся нейронные обыкновенные дифференциальные уравнения, которые представляют скрытые состояния в виде динамической системы, данный подход позволяет исследовать нерегулярно наблюдаемые данные [6], а также восстановить параметр динамической системы, однако не исследуются динамические системы с параметром, меняющимся во времени.

В теории оптимальных процессов [7] вводится управляемый процесс

$$\frac{d}{dt}\mathbf{X}(t) = f(\mathbf{X}(t), \mathbf{u}(t)), \quad \mathbf{X}(t_0) = x_0 \quad (3)$$

и задача минимизации функционала

$$J = \int_{t_0}^{t_1} L(\mathbf{X}(t), \mathbf{u}(t)) dt, \quad (4)$$

где  $\mathbf{X}(t) \in \mathbb{R}^n$  — вектор состояния системы в момент времени  $t$ ,  $\mathbf{u}(t) \in \mathbb{R}^r$  — вектор управления в момент времени  $t$ ,  $f(\mathbf{X}(t), \mathbf{u}(t))$  — функция, задающая динамику системы. Однако не рассматривается случай, когда  $\mathbf{X}(t)$  имеет шум.

В работе предлагается метод восстановления параметра динамической системы, меняющегося во времени, путем параметризации его производной. Восстанавливается временной ряд по параметру производной динамической системы, исследуются точки разладки с помощью полученного изменения параметра системы во времени.

### 3 Problem statement

Пусть задан  $\mathcal{D} = (\tilde{\mathbf{X}}_t \mid t \in \{t_i\}_{i=1}^N)$  — временной ряд.

$$\tilde{\mathbf{X}}_t = \mathbf{X}_t + \varepsilon_t, \quad \varepsilon_t \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, 1),$$

где  $\mathbf{X}_t$  порожден динамической системой (1)

$$\frac{d}{dt} \begin{pmatrix} \mathbf{X}(t) \\ \mathbf{w}(t) \end{pmatrix} = \begin{pmatrix} f(\mathbf{X}(t), \mathbf{w}(t)) \\ v_\theta(t) \end{pmatrix}, \quad (5)$$

где  $v_\theta(t)$  — параметризованная динамика.

Пусть задан лосс

$$\mathcal{L}(\mathbf{X}, \hat{\mathbf{X}}) = \frac{1}{N} \sum_{i=1}^N \|\mathbf{X}_i - \hat{\mathbf{X}}_i\|_2^2 \quad (6)$$

Необходимо найти параметр  $\hat{\theta}$ , такой что

$$\hat{\theta} = \arg \min_{\theta} \mathcal{L}(\mathbf{X}, \hat{\mathbf{X}}) \quad (7)$$

## 4 Method

---

### Algorithm 1 Обучение параметра $\theta$

---

- 1: **Вход:** временной ряд  $\mathcal{D}$ , динамическая система  $f(\mathbf{X}, \mathbf{w})$ , производная скрытого состояния  $v_\theta(t)$ , начальные условия  $\mathbf{X}_0, \mathbf{w}_0$
  - 2: **Выход:**  $\hat{\theta}$
  - 3: Инициализировать  $h(t) = (f(\mathbf{X}(t), \mathbf{w}(t)), v_\theta(t))$
  - 4: Инициализировать  $\hat{\theta}$
  - 5: **for** epoch = 1 до max\_epochs **do**
  - 6:   **for** batch в batches **do**
  - 7:      $(\hat{\mathbf{X}}, \hat{\mathbf{w}}) \leftarrow \text{NeuralODE}(h, (\mathbf{X}_0, \mathbf{w}_0), \{t_i\}_{i=1}^N)$
  - 8:     Вычислить ошибку  $\mathcal{L}(\mathbf{X}, \hat{\mathbf{X}})$
  - 9:     Обновить  $\hat{\theta}$
  - 10:   **end for**
  - 11: **end for**
  - 12: **return**  $\hat{\theta}$
-

## 5 Computational experiment

Рассмотрим модель математического маятника с изменяющимся ускорением свободного падения и постоянной длиной, заданную дифференциальным уравнением

$$\frac{d}{dt} \begin{pmatrix} \varphi(t) \\ \omega(t) \\ g(t) \end{pmatrix} = \begin{pmatrix} \omega(t) \\ -\frac{g(t)}{l} \sin(\varphi(t)) \\ 3at^2 + 2bt + c \end{pmatrix} \quad (8)$$

С начальными условиями

$$\begin{pmatrix} \varphi(0) \\ \omega(0) \\ g(0) \end{pmatrix} = \begin{pmatrix} \frac{\pi}{4} \\ 1 \\ 9,81 \end{pmatrix} \quad (9)$$

где  $\varphi(t)$  — угол отклонения маятника в момент  $t$ ,  $\omega(t)$  — угловая скорость маятника в момент  $t$ ,  $l$  — постоянная длина маятника в момент,  $g(t)$  — меняющееся во времени ускорение свободного падения,

$\theta = \begin{pmatrix} a \\ b \\ c \end{pmatrix}$  - обучаемый параметр динамической системы.

Для проведения эксперимента сгенерируем 100 векторов  $\begin{pmatrix} \varphi(t) \\ \omega(t) \end{pmatrix}$

при  $\begin{pmatrix} a \\ b \\ c \end{pmatrix} = \begin{pmatrix} -0.01 \\ 0.1 \\ 0.5 \end{pmatrix}$  равномерно на временном интервале  $t \in [0, 10]$ , решая дифференциальное уравнение (3)-(4) методом Рунге-Кутты четвертого порядка.

При помощи Neural ODE обучим систему (3)-(4) на сгенерированных данных и проанализируем  $\theta$ , изменение  $g(t)$  во времени, а также лосс полученной системы.

## Список литературы

- [1] Hendrik Strobelt, Sebastian Gehrmann, Hanspeter Pfister, and Alexander M Rush. Lstmvis: A tool for visual analysis of hidden state dynamics in recurrent neural networks. *IEEE transactions on visualization and computer graphics*, 24(1):667–676, 2017.

- [2] Yulia Rubanova, Ricky T. Q. Chen, and David Duvenaud. Latent odes for irregularly-sampled time series, 2019.
- [3] Yao Ming, Shaozu Cao, Ruixiang Zhang, Zhen Li, Yuanzhe Chen, Yangqiu Song, and Huamin Qu. Understanding hidden memories of recurrent neural networks. In *2017 IEEE conference on visual analytics science and technology (VAST)*, pages 13–24. IEEE, 2017.
- [4] Rafael Garcia, Tanja Munz, and Daniel Weiskopf. Visual analytics tool for the interpretation of hidden states in recurrent neural networks. *Visual Computing for Industry, Biomedicine, and Art*, 4(1):24, 2021.
- [5] Ricky T. Q. Chen, Yulia Rubanova, Jesse Bettencourt, and David K Duvenaud. Neural ordinary differential equations. In S. Bengio, H. Wallach, H. Larochelle, K. Grauman, N. Cesa-Bianchi, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 31. Curran Associates, Inc., 2018.
- [6] Yulia Rubanova, Ricky T. Q. Chen, and David K Duvenaud. Latent ordinary differential equations for irregularly-sampled time series. In H. Wallach, H. Larochelle, A. Beygelzimer, F. d'Alché-Buc, E. Fox, and R. Garnett, editors, *Advances in Neural Information Processing Systems*, volume 32. Curran Associates, Inc., 2019.
- [7] НС Понтрягин, ВГ Болтянский, МВ Гамкрелидзе, and ЕФ Мищенко. Математическая теория оптимальных процессов. 1983.